

Particionamiento de zonas de falla en la red eléctrica de Costa Rica: Max-Cut, QUBO y QAOA en emuladores H-series

Quantathon CR 2026 — Challenge 1 · Dojo Coding · UCR · OQI · Quantinuum

Repositorio: código, datos y registros con digest SHA-256; un único punto de entrada (`reproduce.py`) regenera cada cifra y figura de este informe.

Resumen. Modelamos el particionamiento en zonas de falla de la red de transmisión costarricense como Max-Cut sobre un grafo derivado de forma determinista y auditable de los datos abiertos del Grupo ICE, lo formulamos como QUBO exacta sin penalizaciones ($E(x) = -\text{cut}(x)$), lo resolvemos con QAOA ($p = 1..3$, 5 semillas) y lo comparamos contra las líneas base clásicas más fuertes (exacto con doble ancla, Goemans-Williamson con cota SDP, greedy, recocido simulado), en local y en los emuladores H-series de Quantinuum vía Nexus; el circuito estrella se porta a Guppy con test de paridad. La comparación escala a la red nacional completa (68 subestaciones) con una familia anidada de corredores e intervalos honestos. El criterio suficiente del reto ($r \geq 0.6$, $p = 1$, 6 nodos) se supera con margen: $r = 0.829$ en `cr6`. QAOA no supera a Goemans-Williamson en ninguna instancia — y ese reporte honesto es el resultado central.

1 Planteamiento del problema

Ante una falla, el operador de una red de transmisión necesita separar la red en islas que contengan la perturbación, abriendo la menor capacidad de transporte posible entre zonas. Modelamos la red regional como un grafo ponderado no dirigido $G = (V, E, w)$: los nodos son subestaciones, las aristas corredores de transmisión y el peso w_{ij} el número de circuitos paralelos del corredor (convención **uniforme**, libre de supuestos; la convención **voltaje** — suma de niveles de tensión en kV — se usa como proxy documentado del costo de apertura). Particionar V en dos zonas maximizando el peso cortado es el problema **Max-Cut**, NP-hard incluso sin pesos.

La instancia estrella, `cr8`, es un corredor de 8 subestaciones del Gran Área Metropolitana (La Caja, Alajuelita, Anonos, Belén, Ribera, Colima, Heredia, Cóncevas) derivado de los datos abiertos del Grupo ICE (70 subestaciones, 102 circuitos; snapshots crudos congelados en el repositorio) mediante un criterio determinista re-ejecutable (corredor greedy más denso desde la subestación de mayor grado, desempate alfabético). Cada instancia congelada lleva su óptimo probado por **dos anclas independientes** y un digest SHA-256 canónico que el cargador verifica: un archivo editado falla ruidosamente en vez de contaminar el benchmark.

2 Formulación: de Max-Cut a QUBO

Con variables binarias $x_i \in \{0, 1\}$ (la zona de cada subestación),

$$\text{cut}(x) = \sum_{(i,j) \in E} w_{ij}(x_i + x_j - 2x_i x_j).$$

Maximizar el corte equivale a minimizar la energía cuadrática binaria $E(x) = x^\top Q x$ con

$$Q_{ii} = -\sum_j w_{ij}, \quad Q_{ij} = Q_{ji} = w_{ij},$$

y la identidad es exacta: $E(x) = -\text{cut}(x)$ para todo x . Max-Cut no tiene restricciones, así que la QUBO no necesita penalizaciones — sin hiperparámetros que calibrar ni soluciones infactibles que filtrar. La identidad se verifica exhaustivamente (2^n estados, test automatizado y reproducible en `notebooks/reto1.ipynb`).

Para QAOA, la QUBO se mapea al hamiltoniano de Ising diagonal $C = \sum_{(i,j) \in E} w_{ij}(1 - Z_i Z_j)/2$, cuyo valor esperado sobre un estado computacional es el corte de ese estado.

3 Líneas base clásicas

La rúbrica pide comparar contra el clásico más fuerte disponible, con referencia publicada. Usamos cuatro:

- **Óptimo exacto.** Enumeración completa ($n \leq 20$) con testigo canónico ($x_0 = 0$); doble ancla independiente congelada en cada instancia.
- **Goemans-Williamson** [1]: relajación SDP resuelta con CVXPY/SCS y redondeo por hiperplanos aleatorios (200 por semilla), razón garantizada ≥ 0.878 . El óptimo del SDP es además una **cota superior rigurosa** del corte máximo — la usamos como ancla de cordura (ningún solver puede excederla) y como denominador honesto en instancias sin óptimo probado.
- **Greedy** de mejora local por flip (garantía clásica $W/2$, razón ~ 0.5).
- **Recocido simulado** con enfriamiento geométrico, multi-semilla.

En todas las instancias con óptimo probado (6–30 nodos), Goemans-Williamson **encuentra el óptimo exacto** — la vara clásica real no es su garantía de 0.878 sino $r = 1.0$.

4 Implementación cuántica

Ansatz. QAOA estándar [2]: capa inicial $H^{\otimes n}$; por cada capa $l \leq p$, fase de costo $e^{-i\gamma_l C}$ (una compuerta RZZ por arista, pesos normalizados a $\max|w| = 1$) y mixer $e^{-i\beta_l B}$ con $B = \sum_i X_i$ (RX por qubit). Convención documentada y consistente en todo el código.

Split híbrido documentado. Los ángulos se optimizan clásicamente sobre la expectativa **exacta** del statevector (grid de arranque en $p = 1$, COBYLA multi-arranque con semillas, warm start $p - 1 \rightarrow p$: calidad monótona en p); el circuito optimizado se **muestrea** después (Aer con semilla o el emulador H-series). El emulador no participa del lazo de optimización — práctica estándar NISQ, declarada como límite.

Verificación agnóstica al backend. Cada corte reportado se recomputa clásicamente desde el bitstring con los pesos enteros originales; los decodificadores de bits de cada backend están congelados con tests.

Motor de expectación vectorizado. Para la escalera nacional ($n \geq 15$) la expectativa se evalúa con un motor propio que explota que la capa de costo es diagonal (fases del espectro de cortes normalizado) y el mixer es un producto tensorial de RX aplicado eje por eje. Paridad probada contra el statevector de Qiskit a 10^{-12} en tests; las instancias publicadas ($n \leq 14$) conservan la ruta Qiskit bit a bit. El presupuesto de optimización reducido para $n \geq 15$ (grid 8×4 , 2 re-arranques, 100 iteraciones COBYLA) descansa en el warm start y en la concentración de ángulos de QAOA [3].

Emuladores Quantinuum vía Nexus. Los circuitos optimizados se recompilan con pytket y se ejecutan en H2-1LE (ideal, tratamiento exacto hasta 26 qubits) y H2-Emulator (modelo de ruido realista H-series): 19 corridas cacheadas con job-id, ángulos, conteos y digest, de modo que el informe completo se regenera sin credenciales.

Port de paridad a Guppy. El circuito estrella (cr8, $p = 1$) se reescribió en Guppy — el SDK recomendado por la organización — y se ejecutó en el emulador Selene/Quest: RZZ descompuesto exactamente como $CX \cdot RZ \cdot CX$ y ángulos en semigiros (convención tket, fijada empíricamente contra $RX(\pi)$ y cubierta por test). La media muestreada cae a 0.8σ de la expectativa exacta (6.039 vs 6.027 ± 0.015 con 4096 shots): mismo circuito, dos SDKs, un solo resultado.

5 Resultados

Criterio oficial. Con $p = 1$ sobre cr6 (6 nodos), $r = 0.829 \geq 0.6$: el resultado suficiente del reto se supera con margen. La métrica es siempre $r = \langle \text{cut} \rangle / \text{óptimo}$ (media $\pm$ desviación estándar sobre 5 semillas), nunca el costo bruto ni una corrida suelta.




Figura 1: cr8-uniforme: r vs p (media $\pm \sigma$, 5 semillas) frente a Goemans-Williamson (que alcanza el óptimo), greedy y la garantía 0.878. La curva punteada es la mejor muestra por corrida: QAOA **encuentra** el óptimo en todas las configuraciones; su valor esperado queda por debajo.

instancia	$r, p = 1$	$r, p = 2$	$r, p = 3$	GW / óptimo
cr6-uniforme	0.829 ± 0.000	0.885 ± 0.008	0.930 ± 0.002	1.000
cr8-uniforme	0.861 ± 0.000	0.904 ± 0.006	0.931 ± 0.011	1.000
cr8-voltaje	0.859 ± 0.000	0.904 ± 0.000	0.920 ± 0.013	1.000
ieee9-uniforme	0.731 ± 0.000	0.817 ± 0.000	0.849 ± 0.019	1.000
ieee14-flujo	0.761 ± 0.000	0.842 ± 0.001	0.861 ± 0.017	1.000

Emuladores reales. Las mismas configuraciones en H2-1LE reproducen la referencia local dentro del error de muestreo (p. ej. cr8-uniforme: $r(p = 3) = 0.944$ emulado vs 0.931 ± 0.011 local), y el modelo de ruido H-series degrada poco a estas profundidades

(cr8-uniforme $p = 3$: 0.934 con ruido vs 0.944 ideal) — circuitos cortos, 6–14 qubits. El análisis ideal-vs-ruidoso completo está en la figura ruido-h2 del repositorio; reportar hardware sin análisis de ruido es una red flag que evitamos por diseño.

6 Escalado a la red nacional

El mismo criterio determinista de crecimiento produce una familia **anidada** de corredores reales $cr8 \subset cr12 \subset cr16 \subset cr20 \subset cr26 \subset \dots \subset cr68$, donde **cr68** es el grafo nacional de transmisión completo (68 subestaciones, 90 corredores agregados). El reporte distingue dos regímenes con muros documentados:

- **Hasta 20 nodos** — óptimo probado con doble ancla; QAOA con estadística completa (5 semillas, $p = 1..3$). El muro de 20 qubits es el costo de la optimización local de ángulos sobre el statevector denso.
- **De 26 a 68 nodos** — sin pata cuántica posible (26 qubits es el techo exacto del emulador H2); instancias **abiertas**: el archivo congela solo el grafo y su procedencia, sin óptimo. Se reporta el intervalo honesto [mejor corte hallado, cota SDP] y la cota inferior $r \geq \text{mejor}/\text{cota}$.

cr8-uniforme: zonas de falla óptimas (corte = 7)




Figura 2: La red de transmisión nacional (coordenadas reales WGS84, datos ICE) particionada en dos zonas de falla por el mejor corte clásico; corredores cortados en trazo discontinuo, corredor **cr8** resaltado.




Figura 3: Escalado en la familia anidada: QAOA (media $\pm \sigma$) hasta el muro de optimización local; cotas inferiores clásicas (mejor/SDP) hasta el país completo. Zona sombreada: solo clásico.

Extrapolación honesta. La tendencia de r con n a profundidad fija no autoriza afirmaciones de ventaja cuántica: el valor esperado de QAOA a p fijo se degrada al crecer n , mientras GW mantiene su garantía independiente del tamaño y los solvers exactos siguen resolviendo estas escalas en milisegundos. La conclusión de escalado correcta es metodológica: el flujo datos $\rightarrow$ QUBO $\rightarrow$ QAOA $\rightarrow$ verificación funciona idéntico en 6 y en 68 nodos, y declara sus límites en vez de esconderlos.

7 Limitaciones honestas (obligatorio)

1. **QAOA no supera a Goemans-Williamson en Max-Cut.** La garantía de QAOA a $p = 1$ (0.6924 en 3-regulares [2]) es estrictamente menor que la de GW (0.878 [1]); en nuestras instancias GW además encuentra el óptimo exacto. A estas escalas un solver exacto responde en milisegundos: el valor del ejercicio es el flujo híbrido verificado de punta a punta, no una ventaja cuántica.
2. **Split híbrido:** los ángulos se optimizan sobre el statevector local exacto; el emulador muestrea, no optimiza en el lazo.
3. **El emulador remoto no expone semilla por shot:** sus corridas son estadística de muestreo, no réplicas exactas.
4. **Pesos voltaje como proxy documentado** (suma de kV): los datos abiertos del ICE no traen capacidad MVA ni caso de flujo de potencia.
5. **Sin pata cuántica más allá de 20/26 qubits** (optimización local / techo H2): la escalera nacional se reporta con intervalos [mejor clásico, cota SDP], sin óptimos fingidos ni extrapolaciones cuánticas.
6. **La factibilidad física del islanding** (balance generación/carga por isla, criterio N-1) no está codificada en Max-Cut plano; corresponde a la extensión oficial de **constraint mixers** y se deja explícitamente fuera del alcance.

8 Impacto ODS

La cadena causal es concreta: mejores particiones de aislamiento $\rightarrow$ menos capacidad de transporte perdida por falla y restauración más rápida $\rightarrow$ una red que integra más renovable variable sin comprometer resiliencia. Submetas específicas: **ODS 7.b** (modernizar la infraestructura para servicios energéticos sostenibles — Costa Rica opera con $\sim 98\%$ de generación renovable, y la resiliencia de la red es la condición para sostenerla), **ODS 9.1/9.4** (infraestructura fiable y modernizada) y **ODS 13.1** (fortalecer la resiliencia ante desastres relacionados con el clima, primera causa de fallas de transmisión en el país). El uso de **datos reales y abiertos del ICE** — con derivación auditable y re-ejecutable — convierte el argumento ODS en un artefacto verificable, no en una diapositiva.

9 Reproducibilidad

Un único punto de entrada regenera cada cifra y figura:

```
python -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt
python reproduce.py           # todo (≈1 h por la escalera nacional)
python reproduce.py --quick   # smoke en minutos
pytest                        # 59 tests
```

Los registros crudos (runs/) llevan digest SHA-256 y entorno; las corridas de Nexus y Guppy están cacheadas para reproducción offline; el cuaderno narrativo se re-ejecuta con `jupyter nbconvert --execute`. Los datos crudos del ICE están congelados en `data/raw/` con su fecha de descarga y URLs.

Referencias.

1. M. X. Goemans, D. P. Williamson. *Improved approximation algorithms for maximum cut and satisfiability problems using semidefinite programming*. J. ACM 42(6), 1115–1145 (1995).
2. E. Farhi, J. Goldstone, S. Gutmann. *A quantum approximate optimization algorithm*. arXiv:1411.4028 (2014).
3. L. Zhou et al. *Quantum approximate optimization algorithm: performance, mechanism, and implementation on near-term devices*. Phys. Rev. X 10, 021067 (2020); arXiv:1812.01041.
4. Grupo ICE. *Datos abiertos del sistema eléctrico*. datos-ice-se.opendata.arcgis.com (descarga 2026-07-23).
5. Quantinuum. *Nexus, H-series emulators, Guppy/Selene*. Documentación oficial.